

祁杰

全栈工程师

✉ 3057823587@qq.com ☎ 18961994578 📍 江苏 苏州



专业技能

- **大模型应用与智能体 (Agent)**: 熟悉大模型应用开发范式, 掌握 Prompt Engineering、Function Calling、MCP 工具调用、多轮对话、意图识别、上下文/记忆管理、任务编排等核心能力; 能将业务需求抽象为「智能体能力 / 工具能力 / 数据能力 / 平台能力」并工程化落地。
- **RAG 检索增强 / 知识库**: 熟悉 RAG 全链路——文档解析、切块策略、Embedding 向量化、向量数据库检索、Rerank 重排、时效性/权限过滤、引用溯源与防幻觉; 熟悉 LangChain、向量数据库 (Qdrant)、BGE-M3 Embedding 与 reranker, 独立搭建过企业级知识库问答平台。
- **模型接入与 AI Infra**: 熟悉基于 LiteLLM 的**模型调用网关/抽象层** (多供应商切换、预留本地化)、SSE 流式推理服务、Prompt 管理与系统提示词工程; 了解服务监控、日志追踪、**权限认证、限流熔断、配额与 Token 成本治理、灰度发布**等应用侧 Infra 能力。
- **后端开发**: 熟练 Python (FastAPI、Flask、asyncio) 与 Java (Spring Boot), 掌握 RESTful API 设计、Controller-Service-DAO 分层、参数校验、鉴权 (JWT / API Key 双通道)、RBAC 权限与多租户行级隔离 (RLS)、业务处理与数据持久化。
- **数据与存储**: 熟悉 MySQL、PostgreSQL、Redis 与向量库 Qdrant、对象存储 MinIO; 掌握 MyBatis-Plus / SQLAlchemy 等 ORM 及 Liquibase / Alembic 迁移体系, 能设计带缓存、配额、审计的业务表结构。
- **应用效果优化与评测**: 能针对知识检索质量、工具调用准确率、响应时延、Token 成本、稳定性做优化, 并搭建评测集 + 评测运行器 (预留 RAGAS) 与用户反馈闭环, 量化质量基线、驱动迭代。
- **前端与后端联调**: 熟悉 Vue 3 + Element Plus、Flutter / uni-app, 能独立完成管理后台、对话/上传/配置等页面开发并完成前后端联调。
- **工程化与部署**: 熟悉 Docker、Docker Compose、Kubernetes (kustomize)、Nginx、Linux/macOS、Git 分支协作, 具备从需求分析 → 方案设计 → 开发 → 联调测试 → 容器化上线运维的**单人全流程交付能力**。

工作经历

苏州爱意胜自动化科技有限公司, 机器人应用工程师

2025 - 现在
苏州

- 负责公司 AI 智能体产品的后端研发与工程落地, 覆盖智能体配置、多轮对话链路、设备接入与语音 (ASR/LLM/TTS) 通信, 打通前端管理端、Java 后端、Python 语音服务与设备端的完整数据流转。
- 基于 Spring Boot 从零搭建管理端接口, 完成前端 HTTP JSON 请求 → Controller → Service → DAO → MySQL 的业务处理链路; 用 Redis 承载验证码与临时状态, 实现鉴权、设备绑定与状态持久化。
- **主动发起并独立主导企业级 RAG 知识库问答平台 (Finance_RAG) 从 0 到 1 的研发与上线**: 一个人完成需求分析、方案设计、模型接入、RAG 检索管线、权限与配额、前端管理台、容器化/K8s 部署, 并组织业务人员内测、按反馈迭代 (详见项目经历), 沉淀出可复用于多业务场景的智能体/知识库落地方法。
- 维护 MyBatis-Plus、Entity、DTO、Mapper、Liquibase 相关代码, 配合前端与设备端完成登录、设备绑定、配置读取、OTA 下发等接口联调与协议排障。

常州森普科技有限公司(实习), 全栈工程师

2022 - 2024
江苏 常州

- 负责移动端 **Flutter** 组件开发与页面功能实现, 完成通用组件封装与交互逻辑优化。
- 参与 **Flask API** 后端管理与接口开发, 支撑移动端业务功能对接与后台数据处理。
- 负责 **PostgreSQL** 数据库备份、迁移与日常维护, 保障数据安全与环境切换的稳定性。

- 配合项目迭代完成功能联调、问题排查与部署支持，提升系统可维护性与交付效率。

教育经历

硕士-计算机科学, 利物浦大学 深度强化学习算法研究	2024 – 2025
本科-软件工程, 常州工学院 优秀毕业论文; 优秀毕业生; 程序员之家社长	2020 – 2024

项目经历

企业级 RAG 知识库问答平台, 技术栈: FastAPI、LangChain、PostgreSQL、Qdrant、Redis、MinIO、LiteLLM、BGE-M3 + bge-reranker、DeepSeek、Vue 3 + Element Plus、Docker / K8s - 独立完成从需求分析 → 方案设计 → 开发 → 联调测试 → 上线运维的完整流程：面向企业内部知识问答场景，把政策法规、内部 SOP 灌入知识库，提供带出处、可溯源的智能问答工具（架构行业无关，可迁移至政企/客服/办公提效等场景）。 - RAG 检索增强全链路：文档上传 → 解析（PDF/DOCX 含表格）→ 按语义/条款边界切块 → BGE-M3 Embedding 批量向量化 → 写入 Qdrant，异步摄取（arq worker）含状态机、失败回写与删除级联清理；检索采用稠密检索 + bge-reranker 重排 + 时效性/权限过滤，显著提升知识检索准确率。 - 模型接入与推理服务：基于 LiteLLM 做模型调用网关/抽象层（多供应商切换、预留本地化），实现 SSE 流式生成、Prompt 管理与系统提示词工程（仅依据检索内容、强制标注引用、库外拒答、结尾人工复核），有效抑制幻觉。 - 工具调用 / MCP：以 API-first 暴露纯检索接口，并开发 Function Calling / MCP 插件将知识库接入语音智能体，实现"提问 → 工具调用 → 知识库取答 → 生成回答"的闭环。 - AI Infra 与工程治理：JWT + API Key 双通道权限认证、RBAC + scope、多租户 RLS 行级隔离；限流熔断（日调用次数 Redis 计数 429、文档/存储配额 413）；成本与可观测性（Token 成本控制、全链路审计日志、状态追踪）；修复一处提交时机导致的读写竞态（吊销 Key 后毫秒窗口内可复用），提升稳定性。 - 效果优化与评测：搭建评测集 + 评测运行器（引用命中/要点召回/拒答判分，预留 RAGAS）与"有帮助/不准确"反馈闭环，量化质量基线、驱动 badcase 迭代。 - 平台化与部署交付：编写 api / worker / web 三镜像与 kustomize K8s 清单，在真实集群完成"部署 → 迁移种子 → 集群内问答"端到端验证；支持内网私有化部署，沉淀数据合规与交付文档，推动从 PoC 走向可规模化交付。	01/2026 – Present
机器人管理与语音服务, 技术栈: Spring Boot、MyBatis-Plus、MySQL、Redis、Python asyncio、WebSocket、MQTT、OTA、ASR/LLM/TTS - 负责设备管理、智能体配置与语音智能体通信链路后端开发，涉及多轮对话、意图识别、function_call 工具调用、上下文/记忆管理等 Agent 核心能力的工程落地。 - 修复设备注册死循环隐患：验证码冲突时旧逻辑未重新生成 Redis key，调整生成与查询顺序，确保每次冲突重新生成，提升注册接口稳定性。 - 打通 Java OTA 与 Python WebSocket 认证不兼容：对齐 AuthManager 签名规则，在 Java 侧实现基于 clientId deviceId timestamp 的 HMAC-SHA256 token 并经 OTA 下发，保证跨服务鉴权一致。	01/2026 – Present

- **优化设备绑定/激活**：用 Redis 保存激活码、MAC、硬件型号、固件版本等临时状态，绑定成功后持久化用户-设备-智能体关系并清理缓存，避免脏数据。
- **拦截未授权设备资源浪费**：优化 Python ConnectionHandler 绑定状态判断，绑定确认前丢弃音频、按间隔提示，避免未授权设备进入 ASR/LLM/TTS 链路，降低无效算力与 Token 消耗。
- **修复语音队列竞态与 TTS 流控死锁**：通过绑定状态事件、发送队列状态与 sentence_id 重置机制，解决打断后重新唤醒的播放不完整与流控死锁问题，提升可观测性与稳定性。
- **重构 ASR 音频预处理**：将多个 Provider 中重复的 Opus 解码、PCM 合并、临时文件处理抽到基类，统一封装为 AudioArtifacts，降低多模型接入的重复代码与维护成本。

安检机连续x光图片分类, 图片识别分类算法

07/2025 – 09/2025

- 设计对安检机红外扫描出50000张图片进行分类和无重复处理的图像过滤算法：该算法主要利用连续检测出的结果的连续性（在连续的set.size张图片中，重复的图片比较集中），将每一个set控制在一个预定好的参数内，然后对该set进行尺寸分类。通过求像素差，转灰度图，然后求整个差值图的平均值，返回结果。先后使用pHash过滤，然后用ORB 特征点 + Hamming 距离，对尺寸变化不那么敏感。

基于深度学习的篮球姿势识别系统, 数据格式转化/数据库

09/2023 – 06/2024

- 对关节角度计算的算法进行全面参数优化，使得系统得分的鲁棒性得到提高。
- 后端获取算法推导出的计算角度函数的结果进行数据格式转化和表结构优化。

语言

英语

IELTS 6.5 (Speaking 7.0)